# MINERAÇÃO DE TEXTO (Parte 3) - ANÁLISE DE SENTIMENTOS COM CLASSIFICAÇÃO BINARIA

## **Livro:** The Amateur Emigrant **de** Robert Louis Stevenson

#### Instalando o NLTK (NATURAL LANGUAGE TOOLKIT)

```
In [1]:
         pip install nltk
        Requirement already satisfied: nltk in c:\users\mmateus\anaconda3\lib\site-packages
        Requirement already satisfied: click in c:\users\mmateus\anaconda3\lib\site-packages
        (from nltk) (8.0.3)
        Requirement already satisfied: joblib in c:\users\mmateus\anaconda3\lib\site-package
        s (from nltk) (1.1.0)
        Requirement already satisfied: regex>=2021.8.3 in c:\users\mmateus\anaconda3\lib\sit
        e-packages (from nltk) (2021.8.3)
        Requirement already satisfied: tqdm in c:\users\mmateus\anaconda3\lib\site-packages
        (from nltk) (4.62.3)
        Requirement already satisfied: colorama in c:\users\mmateus\anaconda3\lib\site-packa
        ges (from click->nltk) (0.4.4)
        Note: you may need to restart the kernel to use updated packages.
```

### Importando as bibliotecas necessárias:

```
In [2]:
         import nltk
         import matplotlib.pyplot as plt
         import pandas as pd
         import re
         # Importando o Corpora e funções do NLTK...
         from nltk.corpus import stopwords
         from nltk.corpus import opinion_lexicon
         from nltk.tokenize import word tokenize
         nltk.download('stopwords', quiet=True)
         nltk.download('opinion lexicon', quiet=True)
         nltk.download('punkt', quiet=True)
         # ... e do Matplotlib
         plt.style.use('ggplot')
```

## Importando o texto de Stevenson:

```
In [3]:
         df = pd.read_csv('data/TheAmateurEmigrant.txt',sep='\t')\
             .dropna()
         df.head(10)
```

```
Out[3]:
                                                     text
          0
```

THE AMATEUR EMIGRANT

- 2 I first encountered my fellow-passengers on th...
- 3 Thence we descended the Clyde in no familiar s...
- 4 on each other as on possible enemies. A few S...
- 5 already grown acquainted on the North Sea, wer...
- 6 their long pipes; but among English speakers d...
- 7 reigned supreme. The sun was soon overclouded...
- 8 grew sharp as we continued to descend the wide...
- 9 falling temperature the gloom among the passen...

## Preparação do texto:

```
In [4]:
# Processo de Limpeza, organização e tokenização do texto (dados não estruturados)
def clean_text(text):
    text = text.lower()
    text = text.replace("'", '')
    text = re.sub(r'[^\w]', ' ', text)
    text = re.sub(r'\s+', ' ', text)
    text = text.strip()
    return text

df['text'] = df['text'].map(clean_text)
df['text'] = df['text'].map(word_tokenize)

df.head()
```

```
Out[4]: text
```

**0** [the, amateur, emigrant]

1 [the, second, cabin]

- 2 [i, first, encountered, my, fellow, passengers...
- 3 [thence, we, descended, the, clyde, in, no, fa...
- 4 [on, each, other, as, on, possible, enemies, a...

```
In [5]:
    df = df.text.explode().to_frame('token')
    df.head(10)
```

```
Out[5]:
                     token
                       the
           0
           0
                   amateur
           0
                  emigrant
           1
                       the
           1
                    second
           1
                     cabin
           2
                          i
```

```
token
         2
                   first
         2 encountered
         2
                   my
In [6]:
          df.token.value_counts().head(10)
                1548
         the
Out[6]:
         and
                1079
         of
                 860
                 808
         a
                 687
         to
                 498
         was
                 481
         in
                 419
                 406
         he
         had
                 275
         Name: token, dtype: int64
In [7]:
          # Removendo Stop Words
          stopwords = set(stopwords.words('english'))
In [8]:
          df = df[~df.token.isin(stopwords)]
In [9]:
          df.token.value_counts().head(10)
                     129
Out[9]:
         man
         like
                      70
         would
                       67
         said
                       56
         could
                       55
         upon
                       55
                       51
         two
                       50
         steerage
                       46
        Name: token, dtype: int64
```

# Machine Learning: Classificando os sentimentos positivos e negativos com o Opinion Lexicon

```
In [10]:
    sentiment_lexicon = {
        **{w: 'positive' for w in opinion_lexicon.positive()},
        **{w: 'negative' for w in opinion_lexicon.negative()}
}

df['sentiment'] = df['token'].map(sentiment_lexicon)
    df = df[~df.sentiment.isna()] # ommit words out of opinion lexicon

df.head(10)
```

```
Out[10]: token sentiment

3 askance negative
```

```
5
                 friendly
                            positive
               suspicion
                           negative
            7
                supreme
                            positive
                   sharp
                            positive
            9
                  falling
                           negative
                  gloom
                           negative
           11
                  scarce
                           negative
           12
                    cold
                           negative
In [11]:
            df.token.value_counts().head(10)
           like
                       70
Out[11]:
           good
                       46
           well
                       32
           work
                       27
           better
                       23
           sick
                       21
           great
                       17
           enough
                       16
                       12
           hard
           poor
                       11
           Name: token, dtype: int64
```

## Sumarizando as palavras por sentimentos

token sentiment

negative

4

enemies


```
In [12]:
    summary_df = df.sentiment.value_counts().to_frame('n')
    summary_df['prop'] = summary_df['n'] / summary_df.n.sum()
    summary_df.round(3)
```

```
Out[12]: n prop
positive 942 0.522
negative 863 0.478
```

## Gráfico com a Classificação Binária dos sentimentos

```
summary_df.n.plot.bar(legend=False, figsize=(10, 5), grid=False, color='darkblue')
plt.xlabel('Sentimentos')
plt.ylabel('Frequência das palavras')
plt.title('Proporção de palavras com sentimento positivo e negativo', loc='left')
plt.xticks(rotation=0);
```

#### Proporção de palavras com sentimento positivo e negativo



A narrativa de viagem de Stevenson mostra um certo equilíbrio entre palavras com 52,2% dos sentimentos sendo positivos contra 47,8% de negativos; isso se reflete, em termos de quantidade, no gráfico acima. Por se tratar de uma história real, ambientada num navio cuja tripulação era composta, em sua maioria, por homens desempregados (bem pelas esposas e filhos de muitos deles), que estavam em busca de melhores condições de vida na América, esse resultado pode causar surpresa em quem esperava que o tom da história tendesse mais para o lado negativo. No entanto, o escritor soube dosar a sua narrativa com fatos de como esses viajantes se divertiam, a camaradagem que existia entre eles e a esperança que depositavam no Novo Mundo.